Store Sales - Time Series Forecasting

team2
고나경, 김윤진, 김은호, 전소연, 정소영, 최윤서

kaggle 데이터 분석

Store Sales

- Time Series Forecasting

매장에서 판매되는 제품의 **매출 예측**

Additional Notes

public 부문의 임금은 2주마다 15일과 매월 말일에 지급된다.
2016년 4월 16일에 규모 7.8의 지진이 에콰도르를 강타했다
. -구호 활동으로 물, 생필품 거래량 급증

결측치 존재 oil.csv 유가, transactions.csv 거래량

train.csv

- id 거래 번호
- date 판매 날짜
- store_nbr 판매 상점
- Family 제품 유형
- **sales 매출**
- onpromotion 판촉 제품 수

test.csv

train data에서 sales 제외 동일하게 포함

-> sales 예측

- train : 2013-01-01 ~ 2017-08-15
- test : 2017-08-15 ~ 2017-08-31

stores.csv

- store_nbr 상점
- city 도시
- state 주
- type 가게 유형
- cluster 유사 그룹

oil.csv

- date 날짜
- dcoilwtico 유가

transaction.csv

- Date 날짜
- Store_nbr 상점
- Transaction 일별 거래량

holiday events.csv

- Date 날짜
- Type 휴일 종류
- Local 지역/전국 휴일 여부
- Locale_name 지역명
- Description 휴일/이벤트명
- Transferred True(평일),False

EDA

Sales의 시계열 요소

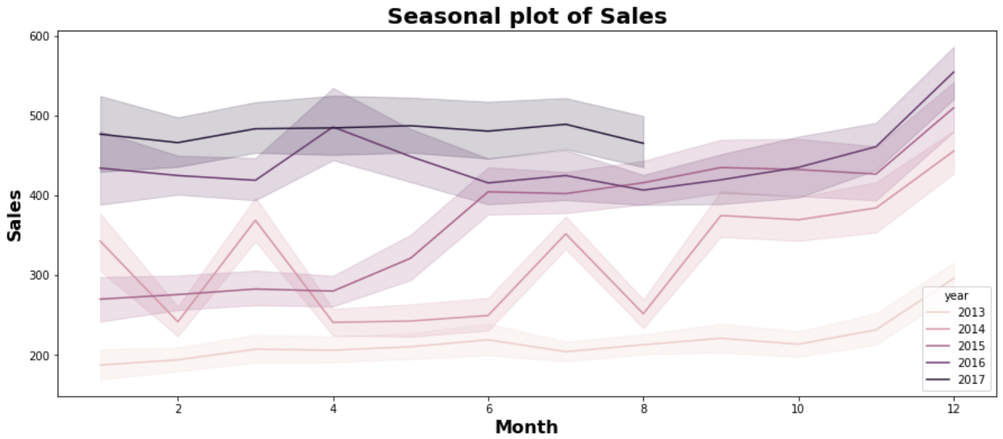

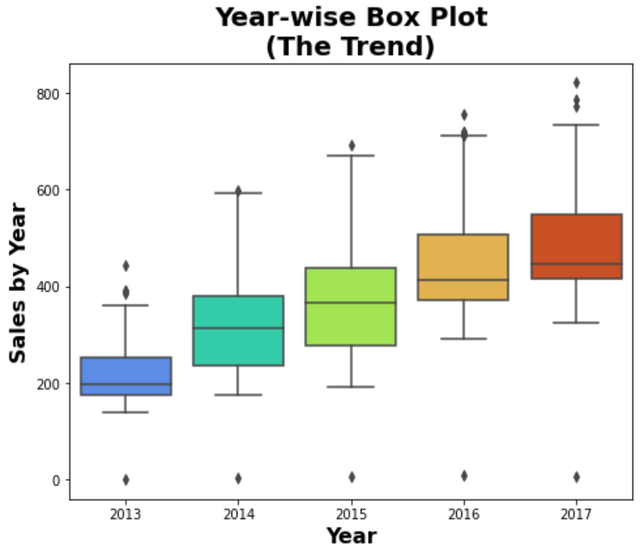

- 해마다 증가하는 추세

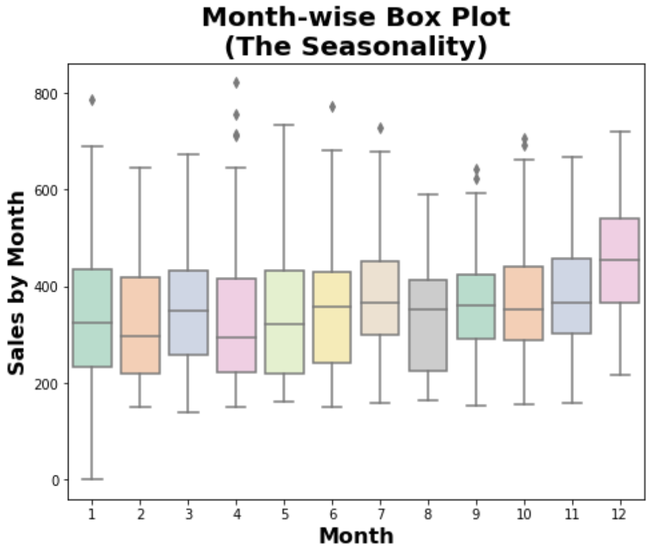

- 뚜렷한 차이는 보이지 않으나
  몇몇 달에서 약간의 차이가 존재함
- 12월에 가장 높은 매출

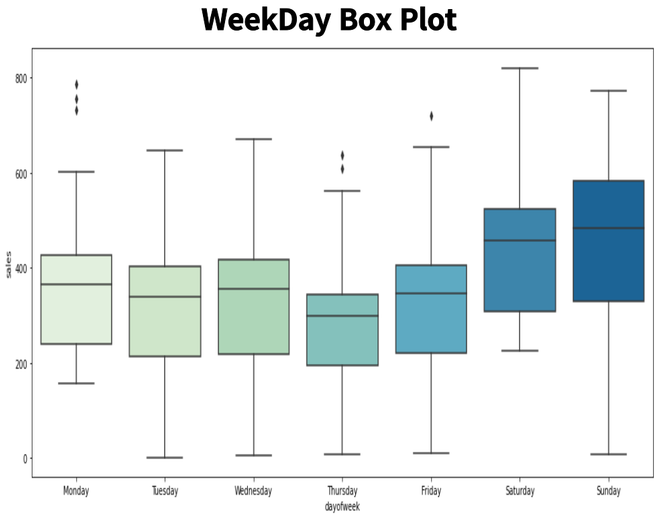

- 요일마다 약간의 차이가 존재
- 주말에 매출 증가
  (일요일에 가장 높은 매출)

EDA

연속형 변수

Average Sales by Onpromotion

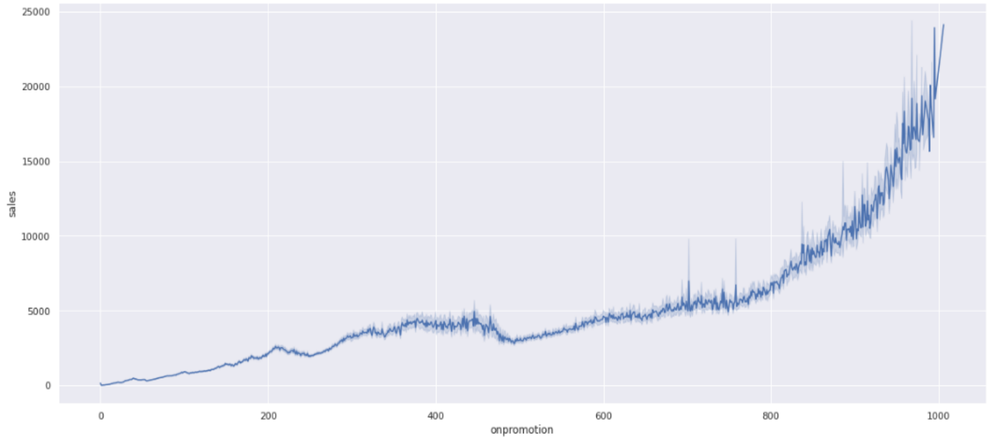

- onpromotion이 증가함에 따라 평균 sales도 증가하는 양상
- 600~1000 구간에서 평균 sales가 급격하게 증가

Average Sales by Transactions

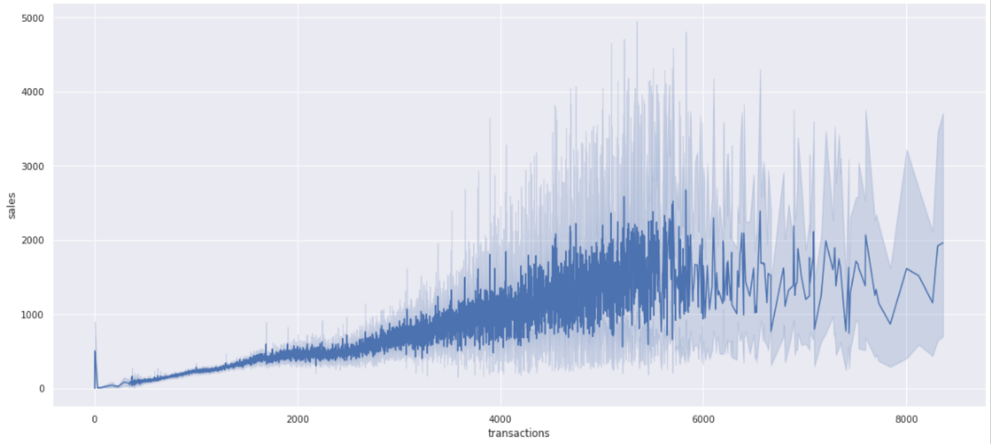

- transactions가 증가함에 따라 sales 평균값과 분산 증가
- transactions가 6000 이상인 구간에서는 레코드 수가 적음

EDA
범주형 변수

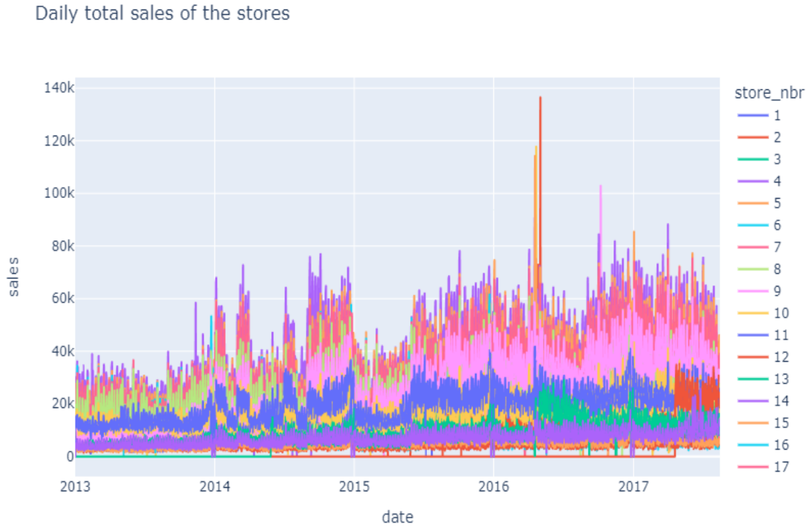

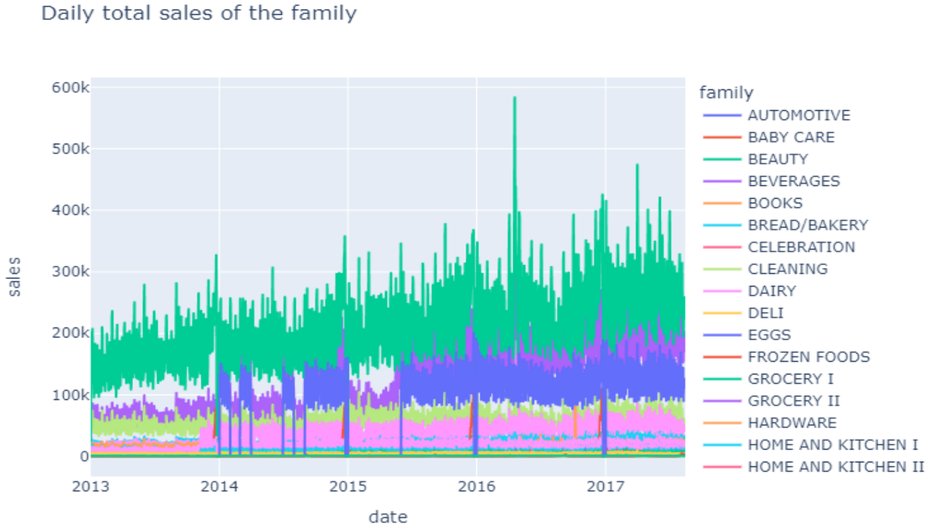

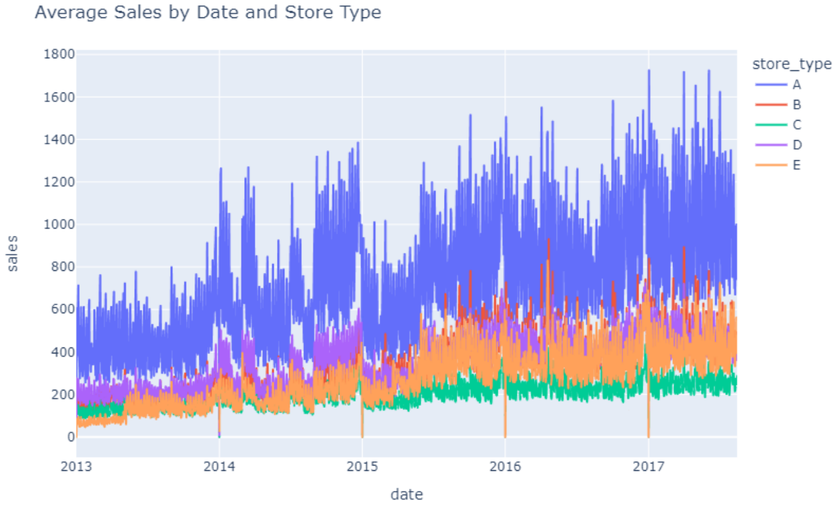

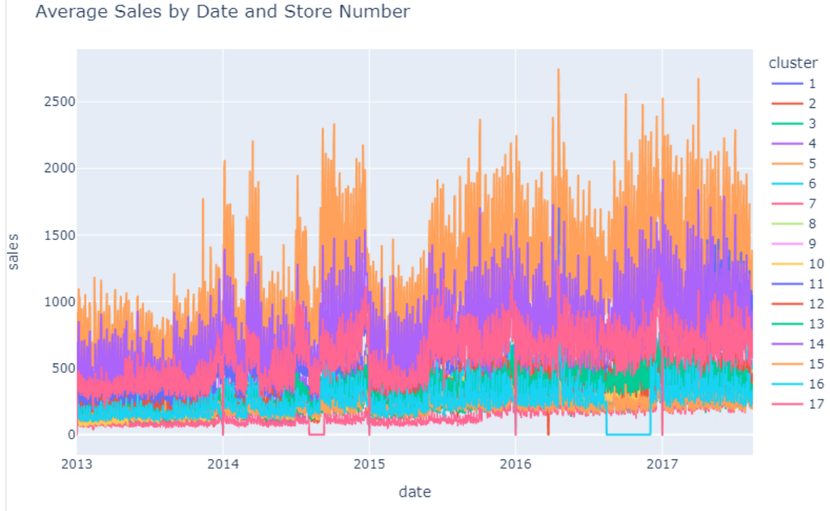

- store_nbr, family, store_type, cluster 에서 범주에 따른 sales에 차이를 보임
- 전체적으로 sales와 그 분산이 증가하는 추세
- 2016년 4월 지진으로 인해 몇몇 범주 (특히 GROCERY I)에서 매출이 급격히 증가
- 다수의 범주에서 연말에 매출이 증가하는 것을 확인할 수 있음

데이터 전처리 - 결측치 처리

1. dcoilwtico (oli price)

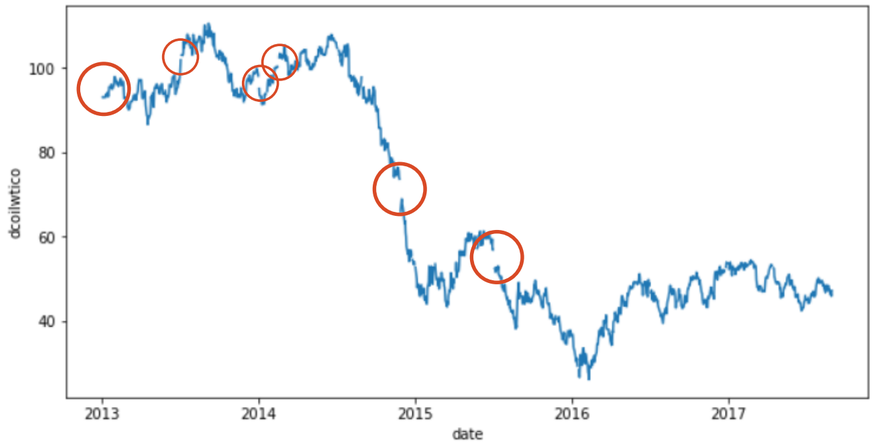

- interporation (보간)

  실측값과 실측값 사이의 결측값을 그라데이션 기법으로 부드럽게 채워나가는 방법

- backward

  바로 뒤에 나오는 실측값으로 앞에 값을 채우는 방법

2. transactions (거래량)

locale_name	description	...	transactions	city	state	type_y
Empty	Empty	...	NaN	Quito	Pichincha	D
Empty	Empty	...	NaN	Quito	Pichincha	D
Empty	Empty	...	NaN	Quito	Pichincha	D
Empty	Empty	...	NaN	Quito	Pichincha	D
Empty	Empty	...	NaN	Quito	Pichincha	D

- linear Regression model

  - 결측이 아닌 데이터를 이용하여 선형회귀모형 적합
  - 종속변수: transactions
  - 예측변수: store_nbr, state, type_y, cluster, dcoilwtico, year, month, weekend, weekday, trend

데이터 전처리 - 파생변수 생성

1. 시계열 관련 변수

- Year (연도)
- Month (달)
- trend
- Weekend (주말)
- Weekday (요일)
- NewYearsDay (새해)

2. hoilday 관련 데이터 변형

type	locale	locale_name	description	transferred
Holiday	Local	Manta	Fundacion de Manta	False
Holiday	Regional	Cotopaxi	Provincializacion de Cotopaxi	False
Holiday	Local	Cuenca	Fundacion de Cuenca	False
Holiday	Local	Libertad	Cantonizacion de Libertad	False
Holiday	Local	Riobamba	Cantonizacion de Riobamba	False

- 'no_work_day' feature 생성

  - 실제로 유의미하고(transferred = 'False'), 국가적인 행사이며(locale = 'National'), 휴일인 날(type = 'Holiday', 'Additional', 'bridge')을 선택

  - 위에서 선택한 날을 weekend 열과 OR 연산

- 기념일 feature 생성

  - description 정보를 활용하여 Earthquake, Football, Cyber Monday, Black Friday, Dia de la Madre(어머니날) feature 생성

데이터 전처리 - family 변수 그룹화

비슷한 특성을 가진 family 변수를 그룹화 한 후, 그룹화 한 것과 그룹화하지 않는 것의 rmsle 비교

Tools	AUTOMOTIVE, HARDWARE, LAWN AND GARDEN, PLAYERS AND ELECTRONICS
LifeStyle	BEAUTY, LINGERIE, LADIESWEAR, PERSONAL CARE, CELEBRATION, MAGAZINES, BOOKS, BABY CARE
Home	HOME APPLIANCES, HOME AND KITCHEN I, HOME AND KITCHEN II, HOME CARE, SCHOOL AND OFFICE SUPPLIES
Food	GROCERY II, PET SUPPLIES, SEAFOOD, LIQUOR,WINE,BEER
Daily	DELI, EGGS

그룹화 O 성능

training : 1.471248

validation : 1.322420

그룹화 X 성능

training : 0.311052

validation : 0.712528

그룹화하지 않는 것이 더 좋은 성능을 보임

데이터 전처리

1. onehotencoding

pd.get_dummies(drop_first = True)

store_nbr(54개의 값들)

store_nbr
1
1
1
1
1
...
9
9
9
9
9

->

store_nbr_2	store_nbr_3	...	store_nbr_53	store_nbr_54
0	0		0	0
0	0		0	0
0	0		0	0
0	0		0	0
0	0		0	0
...	...		...	...
0	0		0	0
0	0		0	0
0	0		0	0
0	0		0	0
0	0		0	0

type_y(5개의 값들)

type_y
D
D
D
D
D
...
B
B
B
B
B

->

type_y_B	type_y_C	type_y_D	type_y_E
0	0	1	0
0	0	1	0
0	0	1	0
0	0	1	0
0	0	1	0
...	...	...	...
1	0	0	0
1	0	0	0
1	0	0	0
1	0	0	0
1	0	0	0

family(33개의 값들)

family
AUTOMOTIVE
BABY CARE
BEAUTY
BEVERAGES
BOOKS
...
POULTRY
PREPARED FOODS
PRODUCE
SCHOOL AND OFFICE SUPPLIES
SEAFOOD

->

family_EGGS	family_FROZEN FOODS
0	0
0	0
0	0
0	0
0	0
...	...
0	0
0	0
0	0
0	0
0	0

데이터 전처리

2. Min-Max Normalization

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

min-max normaliztion 전

onpromotion	dcoilwtico	transactions
0	93.140000	1420.876311
0	93.140000	1420.876311
0	93.140000	1420.876311
0	93.140000	1420.876311
0	93.140000	1420.876311
...	...	...
1	40.546667	2115.000000
1	40.546667	2115.000000
3	40.546667	2115.000000
0	40.546667	2115.000000
1	40.546667	2115.000000

->

min-max normaliztion 후

onpromotion	dcoilwtico	transactions
0.000000	0.792965	0.169385
0.000000	0.792965	0.169385
0.000000	0.792965	0.169385
0.000000	0.792965	0.169385
0.000000	0.792965	0.169385
...	...	...
0.001350	0.170042	0.252484
0.001350	0.170042	0.252484
0.004049	0.170042	0.252484
0.000000	0.170042	0.252484
0.001350	0.170042	0.252484

데이터 분할

1. train_data

(date : 2013-01-01 ~ 2017-08-15)

1-1)sub_train_data

(date : 2013-01-01 ~ 2016-07-31)

1-2)valid_data

(date : 2016-08-01 ~ 2017-08-15)

2. test_data

(date : 2017-08-16 ~ 2017-08-31)

모델 적합

- linear regression

$$y_i = \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i \,, \qquad i = 1, \ldots, n,$$

: 종속 변수 y와 예측 변수 사이의 선형 관계를 모델링

선형 회귀 장단점

- 특성이 많은 데이터셋의 경우 성능이 우수하다. (장점)
- 모델의 복잡도를 제어할 방법이 없어서 과대적합이 되기 쉽다. (단점)

  * 모델의 정규화로 과대적합을 제어할 수 있다.

    : 규제를 통해 정규화(Ridge, Lasso, Elastic net…)

training

2.4700

validation

2.3188

모델 적합 - Lasso

$$\sum_{i=1}^{n}\left(y_i-\beta_0-\sum_{j=1}^{p}\beta_j x_{ij}\right)^2+\lambda\sum_{j=1}^{p}|\beta_j| = \mathrm{RSS}+\lambda\sum_{j=1}^{p}|\beta_j|.$$

- MSE가 최소가 되게 하는 가중치와 편향 + 가중치들의 절댓값의 합 최소
- 가중치의 모든 원소가 0이 되거나 0에 가깝게 되어야 함

주요 파라미터

- alpha 알파 (L1 규제 계수)

성능

알파값 0.05 일때,

training : 2.452747

validation : 2.317404

모델 적합 - Ridge

$$\sum_{i=1}^{n}\left(y_i-\beta_0-\sum_{j=1}^{p}\beta_j x_{ij}\right)^2+\lambda\sum_{j=1}^{p}\beta_j^2 = \mathrm{RSS}+\lambda\sum_{j=1}^{p}\beta_j^2$$

- MSE가 최소가 되게 하는 가중치와 편향 + 가중치들의 제곱의 합 최소
- 가중치는 0에 가까워질 뿐 0이 되지는 않음

주요 파라미터

- alpha 알파 (L2 규제 계수)

성능

알파값 0.05 일때,

training : 2.448911

validation : 2.305556

(alpha값을 높이면 훈련 세트의 성능은 나빠지지만 일반화에는 도움이 됩니다)

모델 적합
- XGBoost

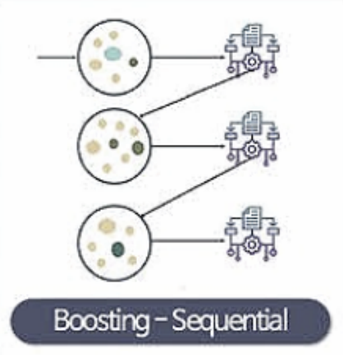

Boosting

- 여러 개의 모델을 결합하는 앙상블 방식 중 하나
- 각 단계의 weak learner는 이전 단계의 weak learner의 잘못 예측된 데이터들에 가중치를 반영하면서 단계적으로 모델 구축

XGBoost의 주요 특징

- level-wise 방식으로 분할 후 가지 치기
- 교차 검증 내장
  xgboost.cv( )
- 과적합 규제
- 결측값 자체 처리

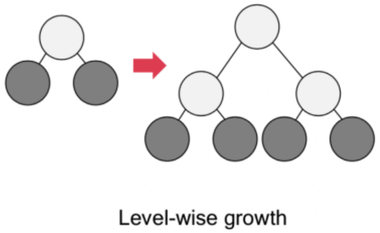
Level-wise growth

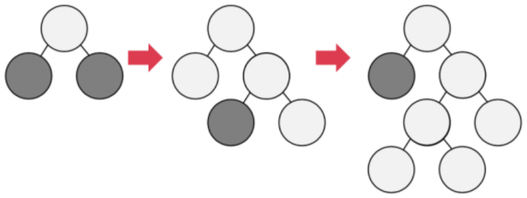
Leaf-wise growth

주요 부스터 파라미터

- eta : 학습률
- num_boost_around : 생성할 학습기의 수
- min_child_weight : 관측치에 대한 가중치 합의 최소
- gamma : 리프노드의 분할을 결정할 최소손실 감소값
- max_depth : 최대 트리의 깊이
- subsample : 단계마다 사용할 샘플의 비율
- colsample_bytree : 트리마다 사용할 feature의 비율
- lambda : L2 규제 파라미터
- alpha : L1 규제 파라미터

베이지안 최적화

- eta : 0.149
- num_boost_around : 2500
- min_child_weight : 0.581
- gamma : 5.388
- max_depth : 12
- subsample : 0.946
- colsample_bytree : 0.975
- lambda : 0.156
- alpha : 67.417

training

0.6783

validation

0.9676

모델 적합 - lightGBM

- 주요 파라미터

- boosting : 부스팅 방식
- learning_rate : 학습률
- max_depth : 나무의 깊이
- num_leaves : 최대 leaf node의 수
- feature_fraction : feature sampling
- bagging_fraction: data sampling

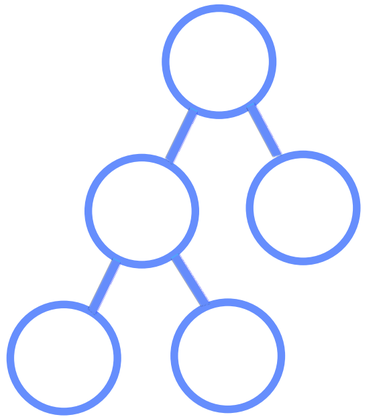

leaf-wise

boosting : 'dart'(default), 'goss'	'goss'
learning_rate : (0.01, 0.1)	0.03
max_depth : (30, 100)	43
num_leaves : (100, 10000)	8391
feature_fraction : (0.5, 0.9)	0.9
bagging_fraction : (0.4, 0.9)	0.5

training

0.8811

validation

0.8991

모델 적합 - Random Forest - 최종모델

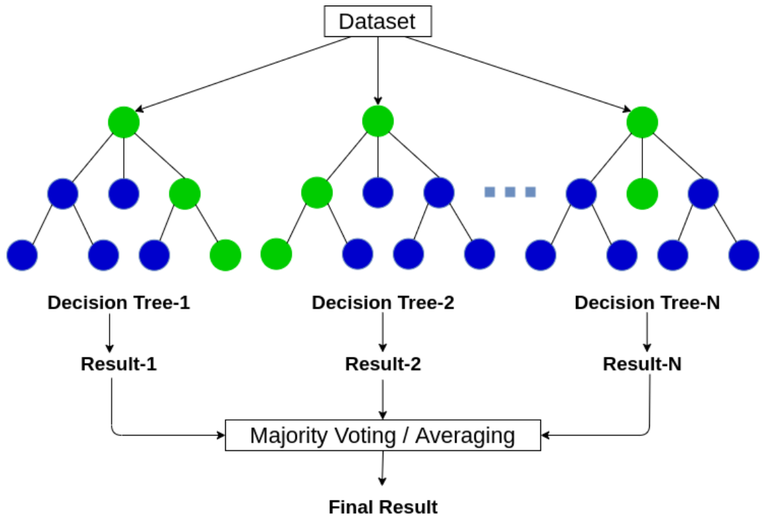

출처 : https://www.analyticsvidhya.com/blog/2020/05/decision-tree-vs-random-forest-algorithm/

- 여러 개의 결정 트리가 각자의 샘플 데이터로 학습
- 최종적으로 투표나 평균을 통해 결과를 결정

주요 파라미터

- n_estimators 결정트리의 개수
- max_depth 트리의 최대 깊이
- min_samples_split 노드 분할에 필요한 최소한의 샘플 데이터 수
- min_samples_leaf 말단 노드에 필요한 최소한의 샘플 데이터 수
- max_features 최적의 분할을 위해 고려할 최대 feature 수
- max_leaf_nodes 말단 노드의 최대 개수

- n_estimators 100
- min_samples_leaf 10
- min_samples_split 10

성능

training : 0.4867

validation : 0.6991

test: 0.52408

아쉬웠던 부분

1. lasso, Ridge 상호작용 넣은 모델 (104 columns -> 5460 columns)

- 상호작용항 생성 : PolynomialFeatures(degree=2,interaction_only=False,include_bias=False)

```
MemoryError
<ipython-input-39-ba6e52b85aa2>
```

- 메모리 에러로 sub_train_data (100000행), valid_data(100000행)만 사용-

1) Lidge(alpha = 30)

```
훈련데이터 rmsle:  1.586924924998741
검증데이터 rmsle:  3.9853482596603054
```

2) Lasso(alpha = 10)

```
훈련데이터 rmsle:  1.8023334342920907
검증데이터 rmsle:  2.285426377422259
```

2. SVM

```
from sklearn.svm import SVR

model = SVR(kernel = 'rbf')
model.fit(X_train_data_trans, y_train)
```

- 클래스 결정경계를 찾아주는 방법
- 모델이 돌아가지 않아 결과 확인이 불가능했음
- 좀 더 덜 복잡한 kernel을 사용해보는 시도 (kernel = 'linear')